fit@hcmus

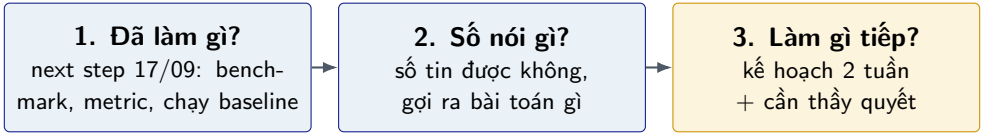
Contextual Biasing cho ASR: Benchmark & Baseline

Báo cáo tiến độ theo next step buổi họp 17/09 • Mục tiêu Interspeech 2027

Nhóm Contextual ASR

03/10/2026

Hôm nay em báo cáo 3 điều



Kết luận trước:

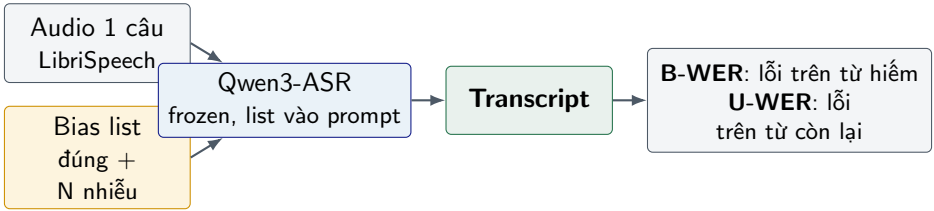
- Benchmark + baseline **đã xong**, khớp số chính thức.
- Qwen3-ASR frozen **dùng context rất tốt** nếu list **ngắn và có từ đúng** (B-WER −46%); list dài hoặc sai thì **vô dụng, thậm chí hại**.
- Các paper mạnh nhất đều giả định **list cho sẵn**. Em đề xuất bài toán **tự dựng list**, và xin 2 tuần làm **feasibility** trước khi chốt method.

Next step buổi 17/09 → trạng thái

Thầy giao	Đã làm	
Dựng benchmark dataset	LibriSpeech + bias list IS21 — đúng bộ mà Hou25 và PTC-Bias dùng	✓
Dataset theo domain	Đề xuất **ConEC** (earnings call, giọng thật, context thật); bộ thuhcsi là **tiếng Trung**	●
Metric	WER / U-WER / B-WER bằng **scorer chính thức**; Recall@K cho bước tạo list	✓
Chạy rồi "xem"	Qwen3-ASR × 7 điều kiện × 2 tập (5.559 câu, 1×RTX 4090); Whisper tái hiện Hou25	✓
Paper không code → tự làm	Đã đối chiếu setting 2 paper; PTC-Bias **có code**, Hou25 **phải tự viết**	●

✓ xong ● đang làm / chờ thầy quyết

Benchmark đo cái gì?



Điều kiện	List đưa vào	Để trả lời
Không context	—	mốc dưới
Oracle	chỉ từ hiếm đúng của câu	**mốc trên** (dùng list tốt nhất được bao nhiêu)
N=100 . . . 2000	từ đúng + N từ nhiễu (setting IS21, Hou25, PTC-Bias)	list càng dài thì sao
Missing	chỉ có từ nhiễu, **không** có từ đúng	list sai có hại không

[Nguồn: Le et al., Interspeech 2021 (IS21); từ hiếm = ngoài 5.000 từ phổ biến. Missing là điều kiện nhóm tự thêm.]

Số có tin được không? — 3 kiểm tra

1. Khớp model card

Qwen3-ASR, không context, test-clean:

1.63 = 1.63 ✓

(số công bố chính thức)

2. Khớp Hou25

Whisper-turbo, B-WER test-clean:

	Hou25	Nhóm
không prompt	10.4	9.43
N=100	7.8	8.04
N=2000	9.8	9.15

Cùng xu hướng ✓

3. Scorer chính thức

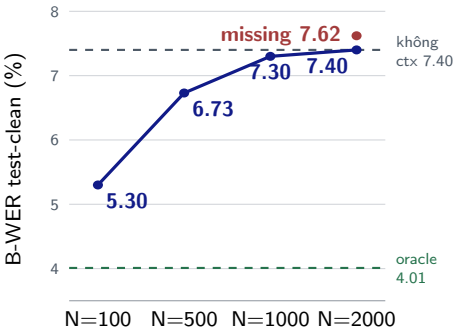
Dùng nguyên script của IS21 → số so 1:1 với paper.

Sanity: hyp = ref → 0/0/0; xoá hết từ hiếm → B-WER 100.

Lưu ý: chuẩn hoá text

"**honour**" vs "**honor**", "**saint**" vs "**st**" ⇒ lệch B-WER 0.5–1 điểm. Nhóm chốt dùng chuẩn hoá của Whisper (khớp model card) và ghi rõ trong paper.

Kết quả chính: Qwen3-ASR-1.7B frozen



clean / other	WER	U-WER	B-WER
Không context	1.63 / 3.41	0.89 / 1.91	7.40 / 16.08
Oracle	1.22 / 2.43	0.87 / 1.80	**4.01 / 7.73**
N=100	1.42 / 3.17	0.93 / 2.17	5.30 / 11.61
N=500	1.60 / 3.33	0.94 / 1.96	6.73 / 14.88
N=1000	1.67 / 3.45	0.95 / 1.98	7.30 / 15.92
N=2000	1.69 / 3.55	0.96 / 2.02	**7.40 / 16.45**
Missing	1.73 / 3.50	0.98 / 1.98	**7.62 / 16.34**

[Nguồn: Context = system prompt "w1, w2, . . ."; chuẩn hoá Whisper; full test-clean 2620 / test-other 2939 câu]

Số liệu nói lên 3 điều

1. Context có ích lớn

Oracle: B-WER **7.40** → **4.01** (−46%), U-WER gần như giữ nguyên.

⇒ Không cần train ASR, chỉ cần **đưa đúng từ**.

2. List dài thì vô dụng

N=100 → 2000: B-WER **5.30** → **7.40**, bằng không context.

Test-other N=2000: **16.45** > 16.08.

3. List sai thì có hại

Missing: **7.62** > 7.40 (clean), **16.34** > 16.08 (other).

⇒ Đưa bừa từ vào prompt là **phản tác dụng**.

Điều kiện để hưởng lợi: list phải **ngắn** và **có từ đúng**.
Khoảng trống cần lấy lại: 7.40 (không context) → 4.01 (oracle) = **3.4 điểm B-WER**.

Paper hiện tại đã giải phần nào? Còn chừa gì?

	Hou25 (Interspeech 2025)	**PTC-Bias** (arXiv 2609.28727)
Cách làm	Chấm điểm từng từ (TTS audio ↔ speech) → top-50 vào prompt	So phoneme theo thời gian → shortlist ≤10 từ + sửa sau decode
Train	scorer	model phoneme
Bias list	**cho sẵn, luôn có từ đúng**	**cho sẵn, luôn có từ đúng**
Kết quả	Whisper, N=100: B-WER 7.8 → 5.4	**Qwen3-ASR**, N=2000: B-WER **4.10 / 7.76**

Đọc số

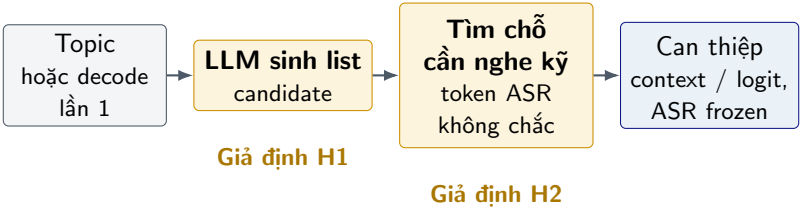
PTC-Bias 4.10 / 7.76 ≈ oracle của nhóm 4.01 / 7.73
⇒ bài **"chọn từ trong list cho sẵn"** gần như **đã kịch trần**.

Chỗ còn trống

Thực tế **không có list**. Đã có bài tự tìm context từ **segment trước** (RAG, EMNLP'25, chỉ đo WER); chưa thấy bài cho **từng câu, không lịch sử**, trên speech LLM frozen, đo B-WER.

[Nguồn: Số PTC-Bias trích từ paper (pipeline của họ); oracle là số nhóm tự chạy — chỉ so sánh tương đối.]

Hướng em đề xuất (chưa chốt method)



H1: list tự sinh có chứa từ đúng?

Nếu LLM không đoán ra từ hiếm thì cả hướng sụp → phải kiểm **đầu tiên**.
Phương án dự phòng: retrieve từ kho 209k (hướng 1 buổi 17/09).

H2: từ sai nằm ở chỗ ASR không chắc?

Nếu đúng → chỉ can thiệp ở đó, giữ được U-WER (tránh lỗi "list sai có hại" ở trên).

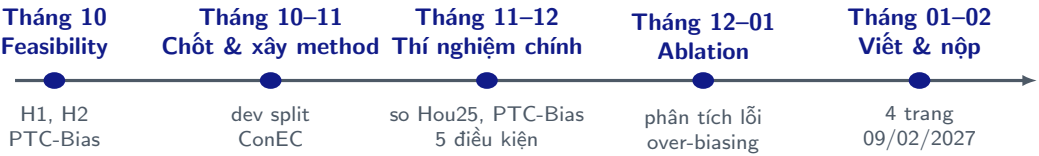
[Nguồn: Định vị theo thời gian đã có ở PTC-Bias ⇒ novelty nằm ở "không cần list cho sẵn".]

2 tuần tới: kiểm H1, H2 trước khi xây method

	Thí nghiệm	Đo	Nếu kết quả xấu
1	LLM sinh $\leq$100 từ từ tên sách/chương, hoặc từ bản decode lần 1	**Recall@K** so với từ hiếm đúng	Chuyển sang retrieve từ kho 209k
2	Đưa list đó vào Qwen3-ASR	B-WER so với 7.40 (không ctx) và 5.30 (N=100)	Cần thêm bước lọc/xếp hạng
3	Log-prob lần decode 1 có "bắt" được vị trí từ hiếm sai không	precision / recall theo vị trí	Bỏ H2, can thiệp cả câu
4	Song song: chạy code PTC-Bias trên pipeline nhóm	có ra 4.10 / 7.76?	Liên hệ tác giả / kiểm setting

Cuối 2 tuần ($\sim$**17/10**) có 4 con số $\Rightarrow$ biết hướng có **khả thi** không $\Rightarrow$ chốt method với thầy.
Tune trên tập dev riêng, không tune trên test.

Lộ trình tới hạn Interspeech 2027 (09/02/2027)



Mốc kiểm soát

17/10: có số feasibility — đi tiếp hay đổi hướng. **Cuối 11**: method thắng baseline ở ít nhất 1 điều kiện khó.

Cần thầy quyết để đi tiếp

	Câu hỏi	Đề xuất của nhóm
1	Chọn bài toán **"không có list cho sẵn"** làm novelty chính?	Đồng ý — phần "chọn" đã kịch trần
2	LLM sinh list: chạy **local** hay gọi **API**?	Local (vd. Qwen3-8B) để tái lập được
3	Hou25: **tự implement** (phải train) hay chỉ **trích số** từ paper?	Trích số trước, implement nếu reviewer cần
4	Bộ domain thật dùng **ConEC** (Earnings-21/22)?	Đồng ý ConEC
5	Dùng lâu dài **1×RTX 4090** trên server?	Đủ cho toàn bộ kế hoạch

Phụ lục: chọn dataset

Bộ	Ngôn ngữ	Speech	Quyết định
LibriSpeech + IS21	EN	thật	✓ **Chính** — 5.559 câu test, kho 209.291 từ hiếm (từ dữ liệu train)
ConEC (Earnings-21/22)	EN	thật	✓ **Domain** — context thật: slide, press release, người dự
ContextASR-Bench	EN/ZH	TTS	● Phụ — có nhãn domain, nhiều entity
thuhcsi/Contextual-Biasing	**ZH**	thật	✗ Từ WenetSpeech; lệch "làm tiếng Anh trước"
ProfASR-Bench	EN	**TTS**	✗ Chỉ tham khảo
Contextual Earnings-22	EN	thật	✗ Chưa public ("upon acceptance")

[Nguồn: fbai-speech/is21_deep_bias; github.com/huangruizhe/ConEC; MrSupW/ContextASR-Bench; github.com/thuhcsi/Contextual-Biasing-Dataset]

Phụ lục: setup chạy và số Whisper

Cấu hình

- 1×RTX 4090, image `nvcr.io/nvidia/pytorch:26.08`.
- Whisper-large-v3-turbo (HF, greedy), prompt "naive", cắt 223 token cuối.
- Qwen3-ASR-1.7B (`qwen-asr` 0.0.6), `context` = system prompt.
- Code: `bench/` (build_is21, run_*, score, eval_retrieval).

Whisper-turbo (clean / other)

plain	WER	B-WER
không prompt	2.64 / 4.87	9.43 / 18.92
N=100	2.55 / 4.20	8.04 / 13.98
N=2000	2.79 / 4.97	9.15 / 18.69
Hou25		
không prompt	3.2 / 5.3	10.4 / 19.7
N=100	2.7 / 4.8	7.8 / 15.2
N=2000	2.9 / 5.2	9.8 / 19.5

[Nguồn: Hou et al., Interspeech 2025, Bảng 1]