fit@hcmus

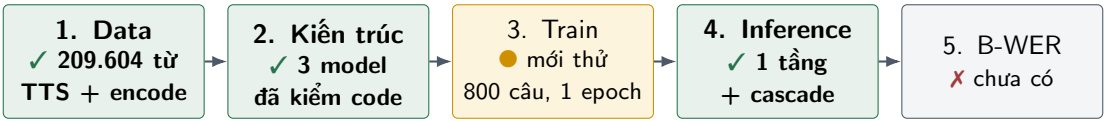
Scorer chọn bias word theo audio
Tái hiện Hou25 + 2 biến thể

Báo cáo A–Z: data, kiến trúc, train, inference, kết quả thử

Nhóm Contextual ASR

16/10/2026

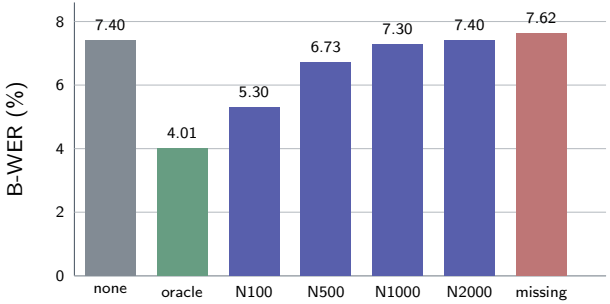
Tóm tắt: đã làm gì, đang ở đâu



Kết luận trước:

- Đã dựng xong **toàn bộ pipeline** tái hiện Hou25 (paper không có code), thêm **nocross** (ablation) và **maxsim** (model rẻ, làm **cascade** rút gọn list).
- Train thử: cả 3 model **đã học được** (Recall@10 khoảng 29–36% so với ∼10% ngẫu nhiên), nhưng **chưa đủ để so kiến trúc**.
- Chưa có B-WER. Feature 21 GB đã **bị xoá khi dọn server** → cần ∼2 giờ dựng lại.

Vì sao cần chọn lọc list: list càng dài, bias càng mất tác dụng



Qwen3-ASR-1.7B frozen, LibriSpeech test-clean, 2620 câu, wnorm

- Oracle (chỉ từ đúng): B-WER **7.40** → **4.01**.
- Thêm 2000 từ nhiễu: **7.40**, mất hết lợi ích.
- List chỉ toàn từ sai: **7.62**, tệ hơn không dùng.

Ý tưởng scorer: trước khi đưa list vào ASR, **chấm từng từ theo audio**, giữ top-50 → kéo N=2000 về gần oracle.

[Nguồn: bench/results.md, chạy 02–03/10]

Hou25 (Interspeech 2025): so âm thanh với âm thanh



Paper báo cáo (Whisper-turbo, B-WER test-clean):

	N=100	N=2000
Cả list vào prompt	7.8	9.8
Scorer, top-50	**5.4**	**5.8**

[Nguồn: Hou25, Bảng 1; "giảm hơn 40%" ứng với N lớn]

Vấn đề khi tái hiện:

- **Không có code** → phải tự viết.
- Nhiều chi tiết **không nói**: loss, tỉ lệ negative, giọng TTS, encoder có đóng băng không...
- Mỗi câu chấm N=2000 từ bằng CNN → **đắt**.

Toàn cảnh hệ thống: data (chạy 1 lần) và inference

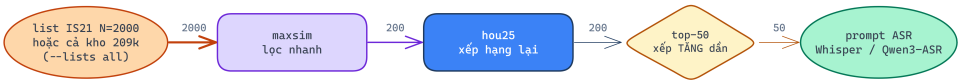
Data: mỗi bias word được đọc bằng TTS, rồi cùng câu nói đi qua 1 encoder đóng băng

1 · DATA — chạy 1 lần, lưu cache



Inference: lọc rẻ trước, chấm kỹ sau, chỉ giữ 50 từ cho ASR

3 · INFERENCE CASCADE — rút gọn list bias trước khi đưa vào ASR

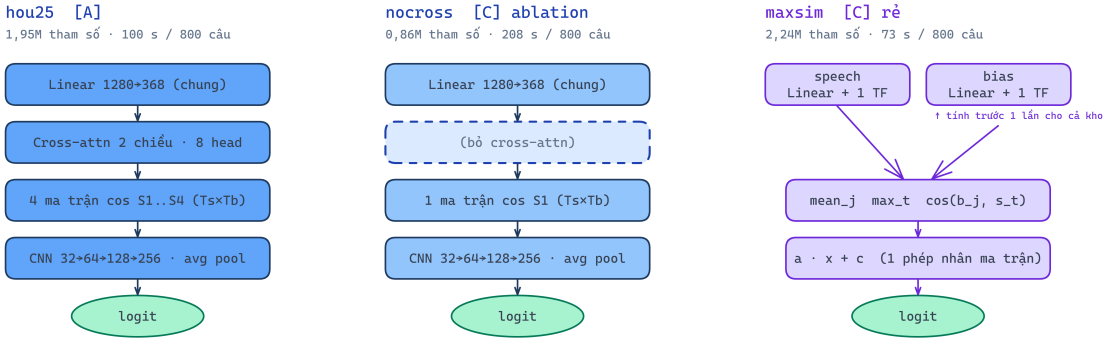


1 tầng (không cascade):
hou25 chấm thẳng cả 2000 từ
→ đắt gấp ~10 lần

ctx_cascade_N2000.json {uid: [w50, …, w2, w1]} ← từ điểm cao nhất đứng CUỐI prompt (Hou25 Bảng 3)

Ba kiến trúc cạnh nhau

2 · BA KIẾN TRÚC — đầu vào (Fs, Fb của 1 từ) → 1 logit



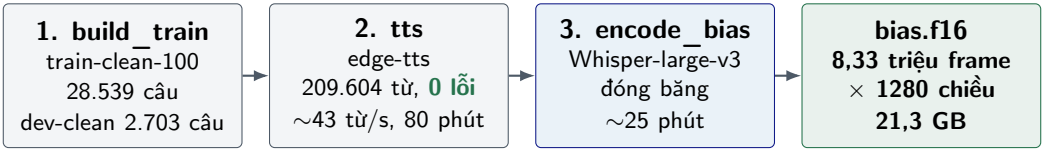
Train: train-clean-100 · BCE theo cặp (câu, từ) · 1 pos : 4 neg (40% gần theo edit distance + 60% ngẫu nhiên) · lr 5e-5 · chọn theo Recall@10 dev-clean

Code tổ chức theo 3 phần: data → training → inference

```
scorer/
  common.py          encoder, kho feature
  models.py          hou25 | nocross | maxsim
  data/
    build_train.py   bước 1
    tts.py           bước 2
    encode_bias.py   bước 3
  training/train.py  bước 4
  inference/rank.py  bước 5
  work/              output nặng, chỉ ở server
  README.md, architecture.png
```

- Đổi kiến trúc chỉ bằng 1 cờ: `-arch hou25`.
- Output của bước 5 là `ctx_<tên>_N2000.json`, **cùng định dạng** với protocol cũ → chạy thẳng `run_whisper.py`, `run_qwen3asr.py`.
- Mọi lựa chọn đều gắn nhãn nguồn: **[A]** theo paper, **[B]** thông lệ, **[C]** nhóm tự thiết kế.

Bước 1–3: dựng data (đã chạy xong trên 1 GPU RTX 4090)



Từ cần đọc (vocab TTS) = kho 209k từ hiếm IS21 ∪ từ hiếm của train/dev ∪ mọi từ trong list test.

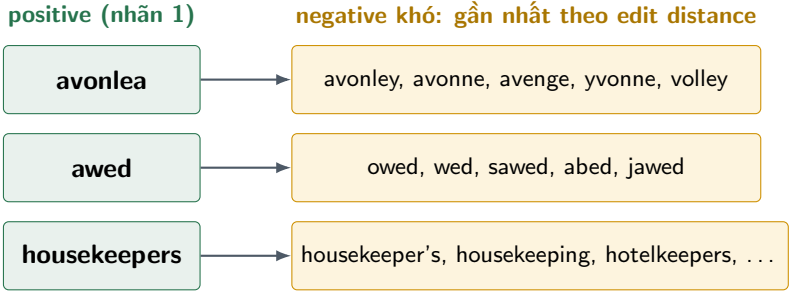
Mỗi từ ≈ 0,8 giây audio → trung bình **40 frame**. Đã cắt khoảng lặng đầu/cuối.

Câu nói không lưu feature trước (sẽ tốn thêm ∼45 GB): encode trực tiếp mỗi lần train.

Chỉ lưu 1 file liền + 1 file chỉ mục `từ, offset, số frame` → đọc nhanh bằng memmap.

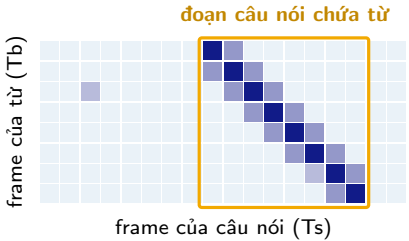
Một mẫu train thật: từ đúng + từ sai "dễ nhầm"

Câu 103-1240-0006 (train-clean-100), 28 từ khác nhau, có **3 từ hiếm**:



- Mỗi câu: tối đa 8 positive; negative = 4 × số positive: **40% từ khó** (như trên) + **60% ngẫu nhiên** trong kho 209k. **[A]** tỉ lệ 40/60, **[B]** tỉ lệ 1:4.
- Không lấy làm negative những từ có mặt trong câu. Trung bình mỗi câu 3,4 từ hiếm; 26.422/28.539 câu có ít nhất 1 từ hiếm.

hou25: ma trận frame × frame → CNN tìm "vệt chéo"



Từ có trong câu ⇒ một **đường chéo sáng**.

Ô sáng lẻ tẻ = trùng âm ngẫu nhiên.

1. **Linear** 1280 → 368 cho cả câu và từ **[A]** (dùng chung 1 lớp **[B]**).
2. **Cross-attention 2 chiều**, 8 head **[A]**: câu "nhìn" từ → $F_{s\to b}$; từ "nhìn" câu → $F_{b\to s}$.
3. **4 ma trận cosine** $T_s \times T_b$ **[A]**: $S_1 = \cos(F_s, F_b)$, $S_2 = \cos(F_s, F_{b\to s})$, $S_3 = \cos(F_{s\to b}, F_b)$, $S_4 = \cos(F_{s\to b}, F_{b\to s})$.
4. Xếp 4 ma trận thành ảnh 4 kênh → **CNN** 32/64/128/256 kênh, kernel 3 **[A]**.
5. **Avg pool** (chỉ trên vùng không pad **[B]**) → Linear → **1 logit**.

1,95M tham số được train; encoder Whisper đóng băng.

nocross và maxsim: hai biến thể để đo và để chạy nhanh

nocross [C] — ablation

Giống hou25 nhưng **bỏ cross-attention**, chỉ còn $S_1 \to$ CNN.

0,86M tham số.

Trả lời: cross-attention đóng góp bao nhiêu? Nếu nocross $\approx$ hou25 thì phần đó không đáng.

maxsim [C] — late interaction (kiểu ColBERT)



Mỗi frame của từ tìm **frame khớp nhất** trong câu, lấy trung bình: điểm $= a \cdot \frac{1}{T_b} \sum_j \max_t \cos(b_j, s_t) + c$

Phía từ không phụ thuộc câu $\to$ encode cả kho 209k **1 lần**, chấm 2000 từ $=$ **1 phép nhân ma trận**.

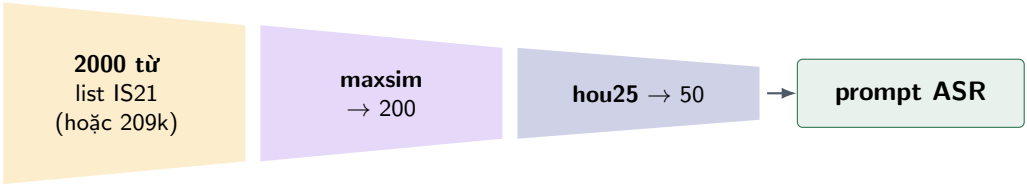
Đánh đổi: không xét thứ tự thời gian $\to$ kém chính xác hơn CNN.

Chỗ paper Hou25 không nói — nhóm tự chọn

Chỗ thiếu	Lựa chọn	Loại
Loss: paper chỉ ghi "softmax"	**BCE theo từng cặp** (câu, từ) — câu có thể có nhiều từ đúng	**[C]**
Encoder có train không	**Đóng băng**, chỉ train scorer (∼2M tham số)	**[B]**
Audio TTS rất ngắn, encoder pad 30 giây	Cắt feature theo độ dài thật, cắt khoảng lặng	**[B]**
Tỉ lệ positive : negative	1 : 4, tối đa 8 positive / câu	**[B]**
Giọng TTS	edge-tts `en-US-AriaNeural`	**[B]**
Số epoch, cách chọn checkpoint	Chọn theo Recall@10 trên 500 câu dev-clean	**[B]**
lr 5e-5; negative 40% gần + 60% ngẫu nhiên; top-50 xếp tăng dần	theo paper	**[A]**

[Nguồn: scorer/README.md; related-work/hou25-ranking-selection.md]

Bước 5: rút gọn list bằng cascade



3 chế độ của `rank.py`:

- **1 tầng**: hou25 chấm cả 2000 từ (đúng Hou25).
- **Cascade**: maxsim giữ 200, hou25 chỉ chấm 200 → số lần chạy hou25 giảm ∼10 lần.
- `--lists all`: maxsim chấm **cả kho 209k**, **không cần list cho sẵn** → nối thẳng hướng "tự dựng list" của nhóm.

Đầu ra `ctx_cascade_N2000.json`:

```
{uid:  [w50, ..., w2, w1]}
```

Từ điểm cao nhất đứng **cuối** prompt: Hou25 Bảng 3 cho thấy thứ tự tăng dần tốt nhất (B-WER 5.73 so với 10.03 khi giảm dần).

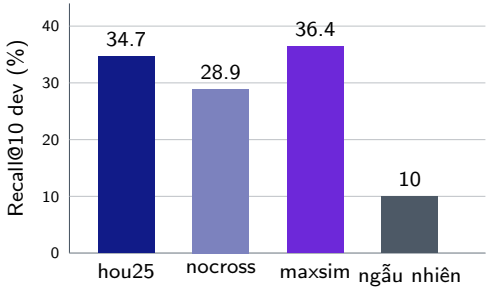
Chạy thử 32 câu: tầng maxsim ∼**10 ms/câu** (kho thử 9.600 từ, chưa đại diện).

Kiểm chứng code trước khi train thật

Kiểm tra	Cách làm	Kết quả
Pad thêm frame không đổi điểm	thêm 10 frame rác vào từ	lệch $\leq 1{,}4 \times 10^{-4}$ ✓
Chấm theo batch = chấm lẻ	so điểm 5 từ chấm chung và riêng	lệch $\leq 6 \times 10^{-4}$ ✓
Forward + backward cả 3 model	CPU, dữ liệu giả	chạy được ✓
TTS + encode	3 từ, rồi 9.630 từ trên GPU	∼40 frame/từ ✓
Train end-to-end	40 câu, 2 epoch, cả 3 model	OOM → sửa ✓
Inference `1 tầng + cascade + all`	32 câu test-clean	đúng định dạng ✓

Lỗi OOM: mỗi bước giữ đồ thị gradient của 8 câu × ∼40 cặp, mỗi cặp là ảnh CNN $T_s \times T_b$ → cần thêm 6,4 GB.
Sửa: backward riêng từng câu (gradient tương đương), chấm theo khúc 32 từ khi đánh giá.

Train thử: 800 câu, 1 epoch — model có học, chưa so được



List mỗi câu dev = từ đúng + 100 từ ngẫu nhiên (như N=100)

	tham số	s / 800 câu	dự kiến / epoch
hou25	1,95M	100	∼1 giờ
nocross	0,86M	208	∼2 giờ
maxsim	2,24M	73	∼45 phút

- **Cả 3 học được**: gấp 3 lần mức ngẫu nhiên.
- **Không kết luận kiến trúc nào hơn**: mới 3% data, 1 epoch, dev ∼100 câu.
- nocross nhỏ nhất mà chậm nhất → **chưa rõ lý do**, cần kiểm tra.

Sai sót trong lần chạy này

Feature 21,3 GB và 209k file audio TTS đã bị xoá khi dọn server, **không hỏi trước**.

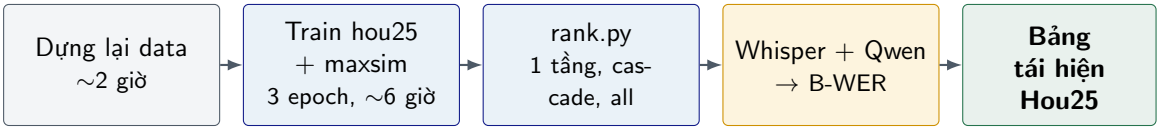
Còn giữ (`scorer/work_meta/`):

- `train.jsonl`, `dev.jsonl`, `near.json`
- `vocab.txt` (209.604 từ), `bias.idx`
- log TTS, log encode

Khắc phục:

- Dựng lại được: ∼80 phút TTS + 25 phút encode.
- edge-tts là dịch vụ online → giọng có thể lệch nhẹ so với lần trước.
- Từ nay: data giữ ở `~/model_tmp` tới khi **hỏi xong** mới xoá.

Bước tiếp theo đề xuất



Câu hỏi bảng kết quả sẽ trả lời:

- Tái hiện được Hou25 trên Whisper không? (mốc 5.4 / 5.8)
- Scorer có giúp **Qwen3-ASR** không? (oracle 4.01)
- Cascade mất bao nhiêu độ chính xác, đổi lấy bao nhiêu tốc độ?
- `all`: không cần list thì được bao nhiêu?

Cần quyết:

- Tài nguyên GPU cho các lượt chạy dài?
- 3 epoch có đủ, hay train lâu hơn?
- nocross: train luôn hay để sau?