fit@hcmus

Scorer chấm bias word theo audio

Audio + bias list → xác suất mỗi từ có trong audio

Nhóm Contextual ASR

17/10/2026

Mục tiêu và tiến độ

Mục tiêu: một **scorer** nhận **audio** và **bias list**, chấm cho mỗi từ khả năng từ đó xuất hiện trong audio.

- **Đã làm xong và train xong** trên LibriSpeech train-clean-100 (28.539 câu).
- Đầu ra là **xác suất** $\in [0, 1]$ = sigmoid(điểm khớp giữa âm vị của từ và audio); học bằng nhãn có / không của dữ liệu train.
- Đo 2 tầng trên benchmark IS21 (giống Hou25 / PTC-Bias):
  - **Scorer tự thân:** chọn đúng bao nhiêu từ?
  - **Đưa vào Qwen3-ASR:** B-WER giảm bao nhiêu?

Kết quả chính: list 2000 từ → còn ∼3 từ/câu, giữ **95%** từ đúng; B-WER của Qwen **7,40** → **4,78** (oracle 4,01).

Bài toán: vì sao có bias list dài, và vì sao cần chọn lọc

ASR sai ở từ hiếm (tên riêng, thuật ngữ):

nói: *"missus* neverbend *you must..."*
Qwen: *"missus* never been *you must..."*

Cách chữa: nhắc trước một **bias list** các từ có thể xuất hiện.

Ngoài đời list dài vì không biết trước người dùng sẽ nói gì:

- gọi điện: cả **danh bạ** (vài trăm–vài nghìn tên)
- họp: tên mọi người + dự án trong công ty

⇒ mỗi câu chỉ 1–2 từ đúng, còn lại là **từ nhiễu**.

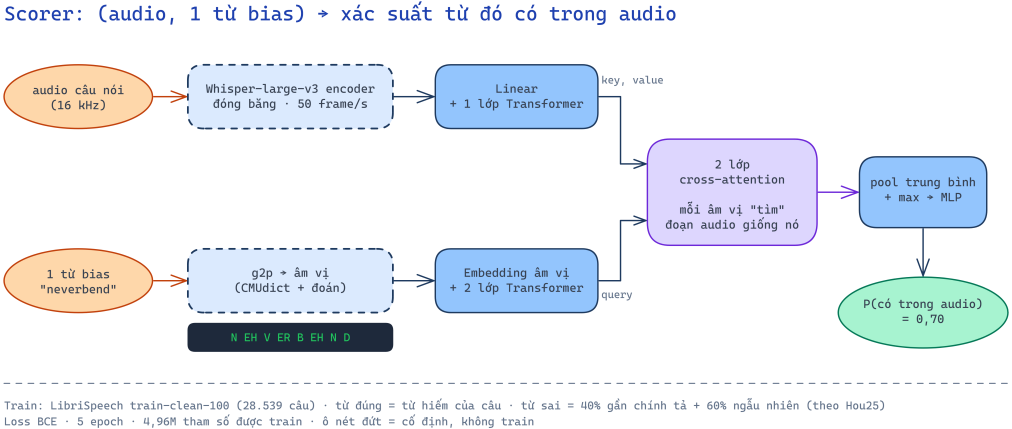
Benchmark IS21 (Le et al. 2021) trên LibriSpeech:

- từ hiếm = ngoài 5.000 từ thông dụng
- list mỗi câu = **từ hiếm thật của câu** + **N từ hiếm ngẫu nhiên** (kho 209k), N = 100 ... 2000

Qwen3-ASR, test-clean	B-WER
không list	7,40
chỉ từ đúng (oracle)	**4,01**
list N = 100	5,30
list N = 2000	**7,40**

B-WER = % từ hiếm bị chép sai. List càng dài, Qwen càng rối → **cần scorer chọn lọc**.

Kiến trúc scorer



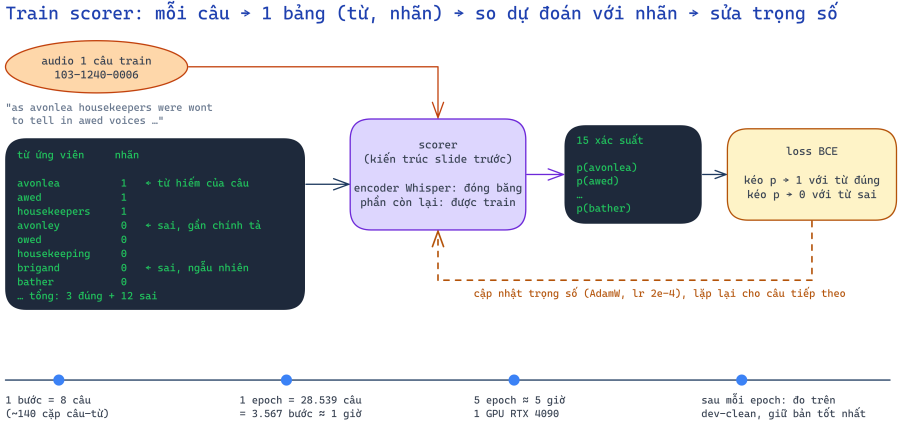
Khác Hou25: từ biểu diễn bằng **âm vị** thay vì audio TTS → từ bất kỳ (kể cả LLM sinh) chấm được ngay; đầu ra là **xác suất** → lọc theo ngưỡng được.

Từng khối làm gì

Khối	Làm gì / vì sao	Train?
Whisper-large-v3 encoder	audio → 50 vector/giây (1280 chiều), mỗi vector mô tả âm thanh của 20 ms. Dùng sẵn, đủ tốt.	không
Linear + 1 lớp Transformer	đưa vector audio về 256 chiều, dạng scorer dễ so	có
g2p	từ → chuỗi âm vị: neverbend → N EH V ER B EH N D. Tra CMUdict, từ lạ thì đoán	không
Embedding âm vị + 2 lớp Transformer	mỗi âm vị → vector 256 chiều, biết ngữ cảnh âm vị bên cạnh	có
2 lớp cross-attention	mỗi âm vị "hỏi" tất cả frame audio: *đoạn nào giống tôi?* Nếu từ được nói, các âm vị tìm thấy đoạn khớp	có
Pool trung bình + max → MLP	gộp kết quả của các âm vị → 1 điểm → sigmoid → xác suất	có

Tổng 4,96M tham số được train. Code: `scorer/models.py` (`PhoneXAttn`).

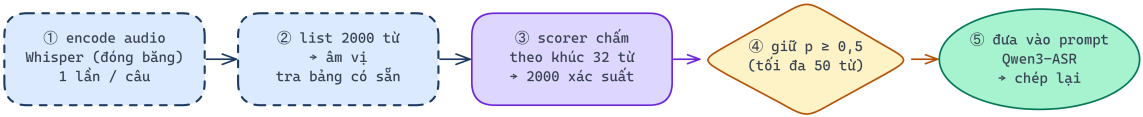
Train thế nào



Từ sai lấy giống Hou25 (40% gần chính tả để model học phân biệt từ nghe gần giống). Mỗi câu: tối đa 8 từ đúng, số từ sai $= 4 \times$ số từ đúng.

Dùng thế nào khi chạy thật

Dùng scorer lúc chạy thật: 5 bước cho mỗi câu (không train gì thêm)



Trong code (thư mục scorer/), chạy cho cả tập test:

```
python -m inference.rank --ckpt ckpt/pxattn/best.pt --name pxattn --lists N2000 --thr 0.5
   → bench/protocol/test-clean/ctx_pxattn_N2000_p0.5.json     {"8455-210777-0012": ["neverbend"], ...}

python run_qwen3asr.py --ctx pxattn_N2000_p0.5          (prompt của câu này: context = "neverbend")
python score.py --whisper-norm  →  B-WER 4.78
```

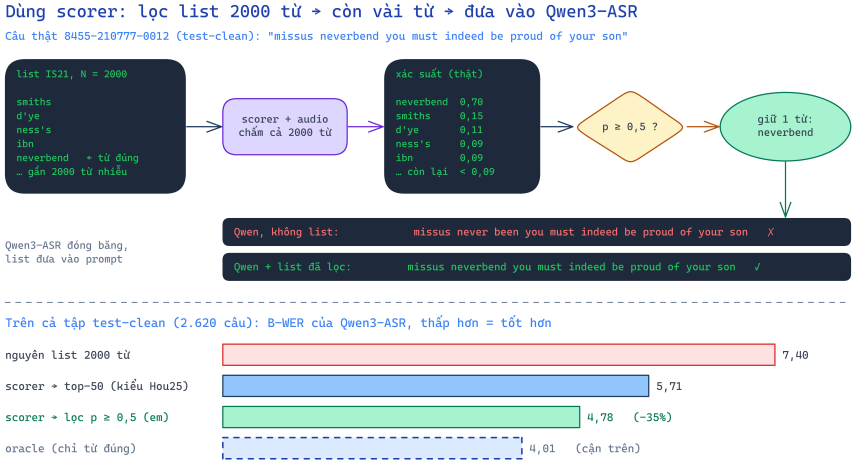
Scorer chọn từ có đúng không? (test-clean, lọc p $\geq$ 0,5)

List đưa vào	Giữ / câu	Precision	Recall	Câu rỗng
100 từ	2,1	98%	95%	25%
2000 từ	3,0	67%	95%	15%
2000 từ, **không có từ đúng**	1,0	—	—	46%

- **Precision**: từ giữ lại có đúng không. **Recall**: từ đúng có bị lọc mất không.
- Từ 2000 từ còn ∼3 từ mà vẫn giữ **95%** từ đúng.
- Biết trả về **rỗng** khi list không có từ đúng (câu không có từ hiếm: 24%).
- List càng dài, từ giữ lại càng lẫn nhiễu: **98% → 67%**.
- Tốc độ: ∼0,5 giây/câu cho 2000 từ trên 1 GPU RTX 4090.

[test-other cùng xu hướng, thấp hơn: 2000 từ → 48% / 89%]

Đưa list đã lọc vào Qwen3-ASR



test-other: 16,45 → 11,57 (top-50) → **9,71** (lọc ngưỡng); oracle 7,73. (scorer IS21, wnorm)

Hạn chế và hướng tiếp theo

Hạn chế

- List dài → độ chính xác tụt (98% → 67%).
- Còn thua **PTC-Bias**: 4,10 / 7,76 (không cần train).
- Đang thử cho scorer **xem thêm bản chép lần 1** của Qwen để ưu tiên từ Qwen chép sai → model **học tắt** (dựa vào bản chép, bỏ qua audio): 6,58. Đang sửa.

Câu hỏi mở

1. Lọc theo ngưỡng đã đủ làm đóng góp chính, hay cần vượt PTC-Bias trước?
2. Ưu tiên **cải thiện scorer**, hay **tự sinh list bằng LLM** khi không có list sẵn?
3. Có cần thêm Whisper để so trực tiếp với số của Hou25?